

NEURO-GPT: TOWARDS A FOUNDATION MODEL FOR EEG

Wenhui Cui¹, Woojae Jeong¹, Philipp Thölke², Takfarinas Medani¹,
Karim Jerbi^{2,3,4}, Anand A. Joshi¹, Richard M. Leahy¹

¹ Ming Hsieh Department of Electrical and Computer Engineering, University of Southern California,
Los Angeles, CA, USA

² Psychology Department, Université de Montréal, Montreal, QC, Canada

³ Mila (Quebec AI research institute), Montreal, QC, Canada,

⁴ UNIQUE (Quebec Neuro-AI research center), QC, Canada

ABSTRACT

To handle the scarcity and heterogeneity of electroencephalography (EEG) data for Brain-Computer Interface (BCI) tasks, and to harness the power of large publicly available data sets, we propose Neuro-GPT, a foundation model consisting of an EEG encoder and a GPT model. The foundation model is pre-trained on a large-scale data set using a self-supervised task that learns how to reconstruct masked EEG segments. We then fine-tune the model on a motor imagery classification task to validate its performance in a low-data regime (9 subjects). Our experiments demonstrate that applying a foundation model can significantly improve classification performance compared to a model trained from scratch, which provides evidence for the generalizability of the foundation model and its ability to address challenges of data scarcity and heterogeneity in EEG. The code is publicly available at <https://github.com/wenhui0206/NeuroGPT>.

Index Terms— Foundation Model, EEG, GPT, Encoder

1. INTRODUCTION

The limited scale of training data for electroencephalography (EEG) based Brain-Computer Interface (BCI) classification tasks poses challenges to applying deep learning models. These models require a large amount of training data to converge and generalize to unseen testing data. However, individual differences can lead to heterogeneous feature representations across subjects [1], which makes it difficult to generalize the model across subjects. EEG’s high-dimensional nature and limited availability for specific tasks create additional barriers to the convergence of these models.

One common approach is to learn generalizable features from large amounts of data using self-supervised learning and then transfer to the task of interest [2]. Here, we address the question of whether we can train a model on large-scale EEG datasets using a self-supervised task and then transfer the pre-trained knowledge to enhance performance on a downstream

task. Large language models (LLMs) in natural language processing (NLP) tasks have proven extraordinarily successful using this approach. Similar models have also shown remarkable performance in other tasks including image and video generation [3], medical question answering [4], and neural activity analysis [5, 6, 7]. Despite the popularity of LLMs, there have been relatively few attempts to adapt them to EEG data. The work in [8] employed a BERT-inspired [9] approach to pre-train a transformer model on massive EEG data using a contrastive self-supervised task. However, it exhibited limited generalizability to downstream tasks.

Here we aim to lay the groundwork for developing foundation models for EEG. We employ a Generative Pre-trained Transformer (GPT) model [10], which uses a decoder-only transformer architecture and is trained to predict the next masked token given a sequence of tokens as input (auto-regressive training). In text-based tasks, a sentence is broken down into tokens as input units to the model. A token can be a few characters or a word, depending on the language and context. To adapt the GPT model to EEG data, we split the whole time series into fixed-length “chunks”, treating each chunk as a token. An EEG encoder is incorporated to extract representative features from raw EEG data. Neuro-GPT is a foundation model consisting of an EEG encoder to extract spatio-temporal features from EEG data, and a GPT model that uses self-supervision to predict the masked chunks. The foundation model is pre-trained on the TUH EEG dataset [11]. We fine-tune the model on a motor imagery classification task where only 9 subjects are available. Experiments showed that the EEG encoder learns meaningful features that are generalizable to the downstream task.

2. METHODS

In this section we introduce the architecture of Neuro-GPT, the pre-training details, and the fine-tuning strategies. We divide the raw EEG data into fixed-length chunks from which we generate a sequence of tokens corresponding to contiguous

NEURO-GPT: EEGの基礎モデルに向けて

Wenhui Cui¹, Woojae Jeong¹, Philipp Thölke², Takfarinas Medani¹,
Karim Jerbi^{2,3,4}, Anand A. Joshi¹, Richard M. Leahy¹

¹ Ming Hsieh 南カリフォルニア大学電気・コンピュータ工学部、米国カリフォルニア州ロサンゼルス ² モントリオール大学心理学部、カナダケベック州モントリオール ³ Mila (ケベック AI 研究所)、カナダケベック州モントリオール、 ⁴ UNIQUE (ケベック ニューロ AI 研究センター)、カナダケベック州

抽象的な

脳コンピュータインターフェース (BCI) タスク用の脳波 (EEG) データの希少性と不均一性を処理し、公開されている大規模なデータセットの力を活用するために、EEG エンコーダーと GPT モデルで構成される基礎モデルである Neuro-GPT を提案します。基礎モデルは、マスクされた EEG セグメントを再構築する方法を学習する自己教師ありタスクを使用して、大規模なデータセットで事前トレーニングされています。次に、運動イメージ分類タスクでモデルを微調整し、データが少ない状況 (9 人の被験者) でのパフォーマンスを検証します。実験では、基礎モデルを適用すると、ゼロからトレーニングしたモデルと比較して分類パフォーマンスが大幅に向上することが実証されており、これは基礎モデルの一般化と、EEG のデータ不足と不均一性の課題に対処する能力の証拠となります。コードは <https://github.com/wenhui0206/NeuroGPT> で公開されています。

Index Terms— 基礎モデル、EEG、GPT、エンコーダー

1. はじめに

脳波 (EEG) ベースの脳コンピュータインターフェース (BCI) 分類タスクのトレーニングデータの規模が限られているため、ディープラーニングモデルを適用することが困難になっています。これらのモデルを収束させて未知のテストデータに一般化するには、大量のトレーニングデータが必要です。しかし、個人差により被験者間で特徴表現が不均一になる可能性があります [1]、被験者間でモデルを一般化することが困難です。EEG の高次元性と特定のタスクに対する可用性の制限は、これらのモデルの収束に対するさらなる障壁となります。

一般的なアプローチの1つは、自己教師学習を使用して大量のデータから一般化可能な特徴を学習し、それに関心のあるタスクに転送することです [2]。ここでは、自己教師タスクを使用して大規模な EEG データセットでモデルをトレーニングし、事前にトレーニングされた知識を下流のタスクに転送してパフォーマンスを向上できるかどうかという問題に取り組みます。

タスク。自然言語処理 (NLP) タスクにおける大規模言語モデル (LLM) は、このアプローチを使用して非常に成功していることが証明されています。同様のモデルは、画像およびビデオ生成 [3]、医療質問応答 [4]、神経活動分析 [5、6、7] を含む他のタスクでも顕著なパフォーマンスを示しています。LLM の人気にもかかわらず、EEG データに適応させる試みは比較的少ないです。[8] の研究では、BERT に触発された [9] アプローチを採用し、対照的な自己教師タスクを使用して大規模な EEG データでトランスフォーマーモデルを事前トレーニングしました。ただし、下流のタスクへの一般化は限られています。

ここでは、EEG の基礎モデルを開発するための基礎を築くことを目指しています。デコーダーのみのトランスフォーマーアーキテクチャを使用し、トークンのシーケンスを入力として与えられた次のマスクされたトークンを予測するようにトレーニングされた、Generative Pre-trained Transformer (GPT) モデル [10] を採用しています (自己回帰トレーニング)。テキストベースのタスクでは、文はモデルへの入力単位としてトークンに分割されます。トークンは、言語とコンテキストに応じて、数文字または単語になります。GPT モデルを EEG データに適合させるために、時系列全体を固定長の「チャンク」に分割し、各チャンクをトークンとして扱います。生の EEG データから代表的な特徴を抽出するために、EEG エンコーダーが組み込まれています。Neuro-GPT は、EEG データから時空間特徴を抽出する EEG エンコーダーと、自己教師を使用してマスクされたチャンクを予測する GPT モデルで構成される基礎モデルです。基礎モデルは、TUH EEG データセット [11] で事前トレーニングされています。被験者が 9 人だけの運動イメージ分類タスクでモデルを微調整しました。実験により、EEG エンコーダーが下流のタスクに一般化できる意味のある特徴を学習することが示されました。

2. 方法

このセクションでは、Neuro-GPT のアーキテクチャ、事前トレーニングの詳細、微調整戦略を紹介します。生の EEG データを固定長のチャンクに分割し、そこから連続したトークンのシーケンスを生成します。

ous data chunks. The GPT model then learns to predict masked tokens. Employing chunks of raw EEG signals directly as input tokens to the GPT model would be problematic. Given the high dimensionality and low signal-to-noise ratio of EEG data [12], predicting raw signals is particularly challenging for the GPT model, and it may not learn meaningful features given the presence of noise. Thus, we introduce an EEG encoder [13] comprising convolutional and transformer layers to extract spatio-temporal features from the raw EEG. We input chunks of EEG into the encoder to generate the embeddings. These embeddings serve as a lower-dimensional and denoised representation of the raw EEG signals, not only simplifying the prediction of the masked chunk for the GPT model but also enhancing its ability to capture informative temporal correlations and patterns. The overall Neuro-GPT pipeline is illustrated in Figure 1.




Fig. 1. Neuro-GPT Pipeline: the EEG encoder takes chunks of EEG data as input and generates embeddings as tokens for the GPT model. The last embedded chunk in the sequence is masked. The GPT model then predicts the masked chunk and a reconstruction loss is computed between the prediction and the original embedding token.

2.1. Neuro-GPT Pipeline

EEG Encoder We adopt an encoder architecture incorporating both convolutional and self-attention modules. This arrangement has achieved state-of-the-art performance in BCI classification tasks [13]. We split the raw EEG signals into N chunks, each of time length T . This results in a sequence of chunks denoted $\{D_1, D_2, \dots, D_N\}$. Each chunk is of dimension $C \times T$, where C is the number of channels. Each chunk is treated as an individual training sample in the encoder. In the convolutional module, we apply a temporal convolution filter to the time series and a spatial convolution filter to the electrodes of the EEG. Then after average pooling, the extracted local features are fed into the self-attention layers to incorporate temporal dependencies within a chunk. The self-attention mechanism combined with convolution will encode the spatio-temporal features of each chunk. The outputs of the encoder are the embedded chunks or tokens: $\{\mathcal{H}(D_1), \mathcal{H}(D_2), \dots, \mathcal{H}(D_N)\}$, where $\mathcal{H}$ denotes the map-



Fig. 2. Causal masking: consider a sequence with four tokens (chunks). We duplicate the sequence three times and progressively mask (represented in orange) one token within each duplicated sequence.

ping learned by the EEG encoder from raw EEG signals to embeddings.

Causal Masking We apply a novel causal masking scheme to the tokens generated by the embedding module. As illustrated in Fig. 2, we first duplicate the sequence of tokens. Starting from the second token, one token is masked and subsequent tokens are zeroed-out in each duplicated sequence. The masked token is replaced with a learnable token $\mathcal{M}$ of the same dimension. So, after causal masking, the input sequence to the GPT model is

$$\begin{aligned} &\{\mathcal{H}(D_1), \mathcal{M}, \mathbf{0}, \dots, \mathbf{0}\}, \\ &\{\mathcal{H}(D_1), \mathcal{H}(D_2), \mathcal{M}, \mathbf{0}, \dots, \mathbf{0}\}, \\ &\dots, \\ &\{\mathcal{H}(D_1), \mathcal{H}(D_2), \mathcal{H}(D_3), \dots, \mathcal{M}\} \end{aligned} \quad (1)$$

The pre-training of Neuro-GPT utilizes a self-supervised task, where the GPT model predicts every masked token in each sequence. We use a causal reconstruction loss defined in Eq. 2 as the self-supervised pre-training objective.

$$\mathcal{L} = \frac{1}{N-1} \sum_{i=2}^N \|\hat{Y}_i - \mathcal{H}(D_i)\|_2^2 \quad (2)$$

$$\text{where } \hat{Y}_i = \mathcal{G}[\mathcal{M} | \mathcal{H}(D_{i-1}), \mathcal{H}(D_{i-2}), \dots, \mathcal{H}(D_1)]$$

where $\mathcal{G}$ denotes the GPT model. We aggregate the reconstruction losses of masked tokens at each position. The predicted token $\hat{Y}_i$ produced by the GPT model is inferred based on the preceding tokens. By predicting the masked token separately from 1, 2, and 3 preceding tokens the model gains insight into the underlying temporal correlations in brain activity across different time scales. Thus the GPT model is potentially able to capture the dynamic evolution of brain activity more accurately.

GPT Model The GPT model employs a decoder-only transformer architecture consisting of a multi-layered stack of self-attention and feed-forward modules, enabling it to capture the global dependencies between tokens. Unlike BERT [9], which randomly masks some tokens in a sequence and the model predicts the masked tokens at random

まず、EEG データのチャンクを GPT モデルに入力します。次に、GPT モデルはマスクされたトークンを予測することを学習します。生の EEG 信号のチャンクを GPT モデルへの入力トークンとして直接使用すると問題が発生します。EEG データの高次元性と低信号対雑音比 [12] を考えると、生の信号を予測することは GPT モデルにとって特に困難であり、ノイズが存在すると意味のある特徴を学習できない可能性があります。そのため、生の EEG から時空間的特徴を抽出するために、畳み込み層と変換層を含む EEG エンコーダー [13] を導入します。EEG のチャンクをエンコーダーに入力して埋め込みを生成します。これらの埋め込みは、生の EEG 信号の低次元でノイズ除去された表現として機能し、GPT モデルのマスクされたチャンクの予測を簡素化するだけでなく、有益な時間的相関とパターンをキャプチャする能力も強化します。Neuro-GPT パイプライン全体を図 1 に示します。




図 1. Neuro-GPT パイプライン: EEG エンコーダーは EEG データのチャンクを入力として受け取り、GPT モデルのトークンとして埋め込みを生成します。シーケンス内の最後の埋め込みチャンクはマスクされます。次に、GPT モデルはマスクされたチャンクを予測し、予測と元の埋め込みトークンの間で再構築損失を計算します。

2.1. ニューロGPTパイプライン

EEGエンコーダ畳み込みモジュールと自己注意モジュールの両方を組み込んだエンコーダアーキテクチャを採用しています。この構成は、BCI分類タスクで最先端のパフォーマンスを達成しています[13]。生のEEG信号を、それぞれの時間長が T である N 個のチャンクに分割します。これにより、 $\{D_1, D_2, \dots, D_N\}$ で示されるチャンクのシーケンスが生成されます。各チャンクの次元は $C \times T$ で、 C はチャンネル数です。各チャンクは、エンコーダ内で個別のトレーニングサンプルとして扱われます。畳み込みモジュールでは、時系列に時間畳み込みフィルターを適用し、EEGの電極に空間畳み込みフィルターを適用します。次に、平均プーリングの後、抽出されたローカル特徴が自己注意層に送られ、チャンク内の時間依存性が組み込まれます。畳み込みと組み合わせた自己注意メカニズムは、各チャンクの時間特徴をエンコードします。エンコーダの出力は埋め込まれたチャンクまたはトークンです： $\{\mathcal{H}(D_1), \mathcal{H}(D_2), \dots, \mathcal{H}(D_N)\}$ 、ここで $\mathcal{H}$ はマップを表します。




図 2. 因果マスクング: 4 つのトークン (チャンク) を含むシーケンスを考えます。シーケンスを 3 回複製し、複製された各シーケンス内の 1 つのトークンを段階的にマスクします (オレンジ色で表示)。

EEG エンコーダーによって生の EEG 信号から埋め込みまで学習された ping。

因果マスクング埋め込みモジュールによって生成されたトークンに、新しい因果マスクング方式を適用します。図2に示すように、まずトークンのシーケンスを複製します。2番目のトークンから始めて、1つのトークンがマスクされ、後続のトークンは各複製シーケンスでゼロに設定されます。マスクされたトークンは、同じ次元の学習可能なトークン M に置き換えられます。したがって、因果マスクング後、GPTモデルへの入力シーケンスは次のようになります。

$$\begin{aligned} & \{\mathcal{H}(D_1), M, 0, \dots, 0\}, \\ & \{\mathcal{H}(D_1), \mathcal{H}(D_2), M, 0, \dots, 0\}, \\ & \dots, \\ & \{\mathcal{H}(D_1), \mathcal{H}(D_2), \mathcal{H}(D_3), \dots, M\} \end{aligned} \quad (1)$$

Neuro-GPT の事前トレーニングでは、自己教師ありタスクを利用します。このタスクでは、GPT モデルが各シーケンス内のすべてのマスクされたトークンを予測します。自己教師あり事前トレーニングの目標として、式 2 で定義された因果再構築損失を使用します。

$$\mathcal{L} = \frac{1}{N-1} \sum_{i=2}^N \|\hat{Y}_i - \mathcal{H}(D_i)\|_2^2 \quad (2)$$

$$\text{where } \hat{Y}_i = \mathcal{G}[M|\mathcal{H}(D_{i-1}), \mathcal{H}(D_{i-2}), \dots, \mathcal{H}(D_1)]$$

ここで、 $\mathcal{G}$ は GPT モデルを表します。各位置でマスクされたトークンの再構築損失を集計します。GPT モデルによって生成された予測トークン $\hat{Y}_i$ は、前のトークンに基づいて推測されます。マスクされたトークンを 1、2、3 個前のトークンから個別に予測することにより、モデルはさまざまな時間スケールにわたる脳活動の根本的な時間的相関関係についての洞察を得ます。したがって、GPT モデルは、脳活動の動的な進化をより正確に捉えることができる可能性があります。

GPTモデルGPTモデルは、自己注意とフィードフォワードモジュールの多層スタックで構成されるデコーダのみのトランスフォーマーアーキテクチャを採用しており、トークン間のグローバルな依存関係を捉えることができる。BERT [9]とは異なり、BERTはシーケンス内のいくつかのトークンをランダムにマスクし、モデルはマスクされたトークンをランダムに予測する。

positions, GPT always predicts the next masked token given preceding tokens, also known as auto-regressive training [14]. This guarantees that the prediction of EEG embeddings considers the causal temporal relationship between tokens, thus improving our model of the underlying brain activity patterns.

2.2. Pre-training

Pre-training Dataset: The large-scale public dataset, Temple University Hospital (TUH) EEG corpus, is used as the pre-training dataset. TUH EEG corpus comprises a diverse archive of clinical EEG recordings from 14,987 subjects with multiple sessions. The archive has over 40 different channel configurations and varying duration of recordings [11]. The sample frequency ranges from 250 - 1024 Hz, with the majority of recordings sampled at 250 Hz.

Preprocessing: We preprocessed the TUH EEG dataset using the Brainstorm software [15] in MATLAB (Mathworks, Inc.). Based on the channel labels, we selected 22 channels corresponding to the extended international 10-20 system (Fp1, Fp2, F7, F3, Fz, F4, F8, T1, T3, C3, Cz, C4, T4, T5, T6, P3, Pz, P4, T6, O1, Oz, O2). Channels with zero or missing signals throughout the recording sessions were marked as bad channels. The signals of the bad channels were interpolated by a weighted average of all neighboring channels with a maximal distance of 5cm between neighbors. EEG recordings were re-referenced to the average of 22 channels. We removed power line noise (60 Hz) using a notch filter and bandpass-filtered the data (0.5-100 Hz). All recordings were re-sampled to 250 Hz. We performed a DC offset correction and removed linear trends from the data. A z-transform was applied along the time dimension within each recording to normalize the data.

Implementation Details: During the pre-training phase, we simultaneously pre-train the entire Neuro-GPT model. After experimenting with various input configurations, we set the standard input as: 32 chunks, each with a length of 2 seconds and a 10% (0.2 second) overlap. We randomly select a starting point for each EEG recording and then sample 32 contiguous chunks. If the total length of the EEG recording is shorter than the length to be sampled (57.8 seconds), we apply zero-padding to the end of the sequence. The attention weights are set to zero for the zero-padded part. In each training batch, one sampled sequence is considered as a single training sample. The EEG encoder consists of two convolutional layers followed by six self-attention layers, with an embedding dimension of 1,080. The first convolutional layer has a kernel size of (1, 25), while the second has a kernel size of (C , 1), with C being the number of channels [13].

We employ the open-source GPT-2 [10] model provided by Hugging Face [16], which has an embedding dimension of 1024. We specify 6 transformer decoder layers in the GPT-2 model. A linear layer is added before the GPT-2 model to project the embedding dimension from 1080 to 1024. We pre-

processed 20,000 EEG recordings from the TUH EEG dataset with a total duration of 5656 hours. We train the model on 19,000 EEG recordings for 135 epochs. The remaining 1000 EEG recordings were used as a hold-out validation set.

2.3. Downstream Fine-tuning

Downstream Dataset: We define the downstream task as motor imagery classification, using the BCI Competition IV Dataset 2a provided by Graz University of Technology [17]. The BCI 2a dataset consists of nine subjects performing four motor imagery tasks: imagining left hand, right hand, feet, and tongue movement. Two sessions were collected on different days for each subject, using 22 Ag/AgCl electrodes at a sampling frequency of 250 Hz. Each recording has 72 trials per task, yielding a total of 288 trials. All trials from both sessions were used as training or testing samples - importantly, no subjects in the training data were included in the testing. Data was bandpass-filtered between 0.5 Hz and 100 Hz and normalized across time for each trial. We extract the sequence from $t = 2s$ to $t = 6s$ for each trial, which corresponds to the period when the cue and motor imagery tasks are performed.

Channel resampling: The downstream dataset has a different subset of 22 channel locations on the scalp from the pre-training dataset. To match the channel configuration between the two datasets, we resampled the downstream data to the pre-training dataset channel configuration using a 22×22 transformation matrix. The transformation matrix was computed by solving the forward and the inverse problem for the source localization, mapping from one sensor configuration to the cerebral cortex and then back to the second configuration [18, 19].

Fine-tuning Details: We fine-tune the pre-trained model on the BCI 2a dataset for the 4-class motor imagery classification task. To fully explore the potential of the foundation model, we designed three fine-tuning strategies:

1. **Encoder-only:** Remove the GPT model and fine-tune the pre-trained EEG encoder only. (Note that in this case the model still benefits from including GPT in pre-training through the self-supervised training of the encoder in combination with the GPT model.)
2. **Encoder+GPT:** Fine-tune the entire Neuro-GPT model.
3. **Linear:** Remove the GPT model, fix the EEG encoder and fine-tune only the linear head (3 linear layers).

All strategies use the same pre-trained model and involve adding a linear head consisting of 3 linear layers to the end of the model for classification. For the Encoder+GPT strategy, we maintain the same number of chunks, the same chunk length, and the same overlapping ratio as used in the pre-training stage. Since only a 4-second sequence is extracted from each EEG recording in the BCI 2a dataset, we apply zero-padding to the end of the sequence. In the Encoder-only strategy, we feed the model with two non-overlapping 2-second chunks, and no zero-padding is applied. For the

GPTは、位置に基づいて、常に前のトークンが与えられた場合に次のマスクされたトークンを予測します。これは自己回帰トレーニングとしても知られています[14]。これにより、EEG埋め込みの予測はトークン間の因果的な時間的関係を考慮することが保証され、基礎となる脳活動パターンのモデルが改善されます。

2.2. 事前トレーニング

事前トレーニングデータセット: 大規模な公開データセットであるテンプル大学病院 (TUH) EEG コーパスが事前トレーニングデータセットとして使用されます。TUH EEG コーパスは、複数のセッションで 14,987 人の被験者から収集した臨床 EEG 記録の多様なアーカイブで構成されています。アーカイブには 40 を超える異なるチャンネル構成とさまざまな記録期間が含まれています[11]。サンプル周波数は 250 - 1024 Hz の範囲で、ほとんどの記録は 250 Hz でサンプリングされています。

前処理: MATLAB (Mathworks, Inc.) の Brainstorm ソフトウェア[15]を使用して、TUH EEG データセットを前処理しました。チャンネルラベルに基づいて、拡張国際10-20システムに対応する22のチャンネルを選択しました (Fp1, Fp2, F7, F3, Fz, F4, F8, T1, T3, C3, Cz, C4, T4, T2, T5, P3, Pz, P4, T6, O1, Oz, O2)。記録セッション全体で信号がゼロまたは欠落しているチャンネルは、不良チャンネルとしてマークされました。不良チャンネルの信号は、隣接チャンネル間の最大距離が5cmのすべての隣接チャンネルの加重平均によって補間されました。EEG記録は、22チャンネルの平均に再参照されました。ノッチフィルターを使用して電源ラインノイズ (60 Hz) を除去し、データをバンドパスフィルター (0.5 - 100 Hz) しました。すべての記録は 250 Hz に再サンプリングされました。DC オフセット補正を実行し、データから線形傾向を除去しました。各記録内の時間次元に沿って Z 変換を適用し、データを正規化しました。

実装の詳細: 事前トレーニング段階では、Neuro-GPT モデル全体を同時に事前トレーニングします。さまざまな入力構成を試した後、標準入力を次のように設定しました。それぞれの長さが 2 秒で、オーバーラップが 10% (0.2 秒) の 32 個のチャンク。各 EEG 記録の開始点をランダムに選択し、連続する 32 個のチャンクをサンプリングします。EEG 記録の合計長がサンプリングする長さ (57.8 秒) よりも短い場合は、シーケンスの最後にゼロパディングを適用します。ゼロパディング部分の注意重みはゼロに設定されます。各トレーニングバッチでは、サンプリングされた 1 つのシーケンスが単一のトレーニングサンプルと見なされます。EEG エンコーダーは、2 つの畳み込み層とそれに続く 6 つの自己注意層で構成され、埋め込み次元は 1,080 です。最初の畳み込み層のカーネルサイズは (1, 25) で、2 番目の畳み込み層のカーネルサイズは (C, 1) で、C はチャンネル数です[13]。

我々は Hugging Face [16] が提供しているオープンソースの GPT-2 [10] モデルを採用している。このモデルの埋め込み次元は 1024 である。GPT-2 モデルには 6 つのトランスフォーマーデコーダー層を指定する。GPT-2 モデルの前に線形層を追加して埋め込み次元を 1080 から 1024 に投影する。

TUH EEG データセットから合計 5656 時間にわたる 20,000 個の EEG 記録を処理しました。135 エポックにわたって 19,000 個の EEG 記録でモデルをトレーニングしました。残りの 1000 個の EEG 記録は、ホールドアウト検証セットとして使用されました。

2.3. 下流の微調整

下流データセット: 下流タスクを運動イメージ分類と定義し、グラーツ工科大学 [17] が提供する BCI コンペティション IV データセット 2a を使用します。BCI 2a データセットは、左手、右手、足、舌の動きをイメージするという 4 つの運動イメージタスクを実行する 9 人の被験者で構成されています。各被験者について、異なる日に 2 回のセッションが収集され、22 個の Ag/AgCl 電極が使用され、サンプリング周波数は 250 Hz です。各記録にはタスクごとに 72 回の試行があり、合計 288 回の試行が行われます。両方のセッションのすべての試行がトレーニングサンプルまたはテストサンプルとして使用されました。重要なのは、トレーニングデータ内の被験者はテストに含まなかったことです。データは 0.5 Hz から 100 Hz の間でバンドパスフィルタリングされ、試行ごとに時間にわたって正規化されました。各試行について、手がかりと運動イメージのタスクが実行される期間に対応する $t = 2s$ から $t = 6s$ までのシーケンスを抽出します。

チャンネルの再サンプリング: 下流データセットには、事前トレーニングデータセットとは異なる頭皮上の 22 チャンネル位置のサブセットがあります。2 つのデータセット間のチャンネル構成を一致させるために、 22×22 変換行列を使用して、下流データを事前トレーニングデータセットのチャンネル構成に再サンプリングしました。変換行列は、1 つのセンサー構成から大脳皮質にマッピングし、次に 2 番目の構成に戻すという、音源位置特定に関する順方向問題と逆方向問題を解くことによって計算されました[18, 19]。

微調整の詳細: 4 クラスの運動イメージ分類タスク用に、BCI 2a データセットで事前トレーニング済みモデルを微調整します。基礎モデルの可能性を十分に探求するために、3 つの微調整戦略を設計しました。

1. エンコーダーのみ: GPT モデルを削除し、事前トレーニング済みの EEG エンコーダーのみを微調整します。(この場合、GPT モデルと組み合わせたエンコーダーの自己教師トレーニングを通じて、事前トレーニングに GPT を含めることでモデルにメリットがあることに注意してください。)
2. エンコーダー+GPT: Neuro-GPT モデル全体を微調整します。
3. リニア: GPT モデルを削除し、EEG エンコーダーを修正し、リニアヘッド (3 つのリニアレイヤー) のみを微調整します。

すべての戦略は、同じ事前トレーニング済みモデルを使用し、分類のためにモデルの最後に 3 つの線形層からなる線形ヘッドを追加します。Encoder+GPT 戦略では、事前トレーニング段階で使用したのと同じチャンク数、同じチャンク長、同じオーバーラップ率を維持します。BCI 2a データセットの各 EEG 記録から 4 秒間のシーケンスのみが抽出されるため、シーケンスの最後にゼロパディングを適用します。Encoder のみの戦略では、モデルに 2 つの重複しない 2 秒間のチャンクをフィードし、ゼロパディングは適用されません。

Linear strategy, all the pre-trained parameters from the EEG encoder are frozen during fine-tuning. We only fine-tune the linear head, which takes the output features of the EEG encoder as input. No masking is applied during fine-tuning.

3. EXPERIMENTS AND RESULTS

Fine-tuning Classification Performance: Unlike previous studies which only focused on within-subject classification [20, 13], we performed leave-one-subject-out cross-validation, which is more challenging due to the high inter-subject variance. We compute the average classification accuracy across subjects. To explore the benefits of applying a pre-trained foundation model, we compare the classification performance of a model trained from scratch (w/o pre-training) to that of the same model fine-tuned on the pre-trained foundation model (w/ pre-training). In addition, we compare the proposed Neuro-GPT with BENDR [8], a BERT-inspired transformer model trained on TUH EEG data using contrastive self-supervised learning and then fine-tuned on the BCI classification data. As shown in Table 1, Neuro-GPT significantly improved the classification performance compared with the best performance of BENDR, and outperforms other methods for motor imagery classification using leave-one-subject-out cross-validation.

The performance of models with pre-training surpassed that of models without pre-training for both Linear and Encoder-only fine-tuning strategies, highlighting that applying a foundation model to a downstream task can lead to effective feature learning and, consequently, improved performance. Among the fine-tuning strategies, Encoder-only achieved the best performance, indicating that the encoder learned expressive and generalizable features during pre-training, thus facilitating the learning of distinguishable features for downstream tasks. The Encoder+GPT yielded worse performance, possibly because the GPT model only serves as

an auxiliary component to assist the EEG encoder in encoding meaningful features from raw EEG data. The GPT model has more trainable parameters than the encoder. Fine-tuning a large model on a small data-set can lead to over-fitting. To examine whether the features learned by the foundation model are linearly separable, we input the features generated by the EEG encoder to the linear head for classification. The classification accuracy achieved by fine-tuning only the linear head is 0.443 vs. 0.398 with out pre-training, indicating that the EEG encoder can encode meaningful features through pre-training.

Hyper-parameter Evaluation in Pre-training: To explore the optimal input configurations for the foundation model during pre-training, we conducted experiments with varying numbers of chunks (4, 8, 16, 32), chunk lengths (1s, 2s, 4s), and overlapping ratios (10%, 50%). Different model architectures were also investigated. Key findings include:

- Chunks with a 1-second length are more straightforward to predict (as embedded tokens) but led to poorer downstream performance.
- Chunks with longer lengths are more challenging to predict but enhance downstream performance.
- Increasing the number of chunks is beneficial. Training with 32 and 16 chunks yielded better downstream results than training with 8 or 4 chunks.
- Increasing the overlapping ratio to 50% improved reconstruction, but degraded the downstream performance.
- Increasing the embedding dimension of GPT-2 model (768 $\rightarrow$ 1024) improved downstream performance.
- Reducing the number of self-attention layers in the encoder (6 $\rightarrow$ 4, 2) degraded downstream performance.
- Adding more GPT decoder layers (6 $\rightarrow$ 8, 10) did not improve downstream performance.

4. DISCUSSION

We have demonstrated that pre-training a foundation model on a large-scale EEG dataset boosts downstream task performance. Through exploring different fine-tuning strategies, we discovered that the pre-trained EEG encoder captures inherent and fundamental features of EEG that are generalizable across datasets, leading to significant improvements in classification performance.

5. ACKNOWLEDGMENT

This project is sponsored in part by the NIH under grant R01 EB026299 and in part by the Defense Advanced Research Projects Agency (DARPA) under cooperative agreement No. N660012324006. The content of the information does not necessarily reflect the position or the policy of the Government, and no official endorsement should be inferred.

Method	w/o Pre-train	w/ Pre-train
Linear	0.398 ± 0.054	0.443 ± 0.051
Encoder-only	0.606 ± 0.098	0.645 ± 0.104
Encoder+GPT	0.596 ± 0.090	0.586 ± 0.098
BENDR [8]	/	0.426
SVM [21]	0.361 ± 0.082	/
EEGNet [22]	0.513 ± 0.052	/
CTCNN [23]	0.477 ± 0.151	/
CCNN [24]	0.553 ± 0.101	/
NG-CRAM [25]	0.601 ± 0.102	/

Table 1. A comparison of means and stds of four-class classification accuracy among different methods. The first three rows are three fine-tuning strategies of Neuro-GPT, accuracies reported in other work are shown in the bottom rows.

線形戦略では、EEG エンコーダーからの事前トレーニング済みパラメーターはすべて、微調整中に固定されます。EEG エンコーダーの出力機能を入力として受け取る線形ヘッドのみを微調整します。微調整中にマスキングは適用されません。

3. 実験と結果

分類性能の微調整：被験者内分類のみに焦点を当てた以前の研究[20, 13]とは異なり、被験者間の分散が大きいためより困難な、1被験者を除外したクロスバリデーションを実行しました。被験者全体の平均分類精度を計算します。事前トレーニング済みの基礎モデルを適用する利点を探るために、最初からトレーニングしたモデル（事前トレーニングなし）の分類性能を、事前トレーニング済みの基礎モデル（事前トレーニングあり）で微調整した同じモデルの分類性能と比較します。さらに、提案されたNeuro-GPTを、対照的自己教師学習を使用してTUH EEGデータでトレーニングされ、その後BCI分類データで微調整されたBERTに触発されたトランスフォーマーモデルであるBENDR [8]と比較します。表 1 に示すように、Neuro-GPT は BENDR の最高性能と比較して分類性能を大幅に向上させ、1つの被験者を除外したクロス検証を使用した他の運動イメージ分類方法よりも優れた性能を発揮しました。

事前学習を行ったモデルのパフォーマンスは、線形およびエンコーダのみの微調整戦略の両方で事前学習を行わないモデルのパフォーマンスを上回り、基礎モデルを下流タスクに適用することで効果的な特徴学習が可能になり、結果的にパフォーマンスが向上することを示しています。微調整戦略の中で、エンコーダのみのパフォーマンスが最も優れていました。これは、エンコーダが事前学習中に表現力豊かで一般化可能な特徴を学習し、下流タスクで識別可能な特徴の学習を促進したことを示しています。エンコーダ+GPTのパフォーマンスは、GPTモデルが単なるモデルとしてしか機能しないため、より劣っていました。

Method	w/o Pre-train	w/ Pre-train
Linear	0.398 $\pm$ 0.054	0.443 $\pm$ 0.051
Encoder-only	0.606 $\pm$ 0.098	0.645 $\pm$ 0.104
Encoder+GPT	0.596 $\pm$ 0.090	0.586 $\pm$ 0.098
BENDR [8]	/	0.426
SVM [21]	0.361 $\pm$ 0.082	/
EEGNet [22]	0.513 $\pm$ 0.052	/
CTCNN [23]	0.477 $\pm$ 0.151	/
CCNN [24]	0.553 $\pm$ 0.101	/
NG-CRAM [25]	0.601 $\pm$ 0.102	/

表 1. 異なる手法間の 4 クラス分類精度の平均と標準の比較。最初の 3 行は Neuro-GPT の 3 つの微調整戦略であり、他の研究で報告された精度は下の行に示されています。

EEGエンコーダーが生じるEEGデータから意味のある特徴をエンコードするのを支援する補助コンポーネント。GPTモデルには、エンコーダーよりも多くのトレーニング可能なパラメーターがあります。小さなデータセットで大きなモデルを微調整すると、過剰適合につながる可能性があります。基礎モデルによって学習された特徴が線形に分離可能かどうかを調べるために、EEGエンコーダーによって生成された特徴を分類のために線形ヘッドに入力します。線形ヘッドのみを微調整することで達成された分類精度は、事前トレーニングなしで0.443に対して0.398であり、EEGエンコーダーは事前トレーニングを通じて意味のある特徴をエンコードできることを示しています。

事前トレーニングにおけるハイパーパラメータ評価：事前トレーニング中の基礎モデルの最適な入力構成を調べるために、さまざまなチャンク数 (4, 8, 16, 32)、チャンク長 (1 秒、2 秒、4 秒)、重複率 (10%、50%) で実験を行いました。さまざまなモデルアーキテクチャも調査しました。主な調査結果は次のとおりです。

- 1 秒の長さのチャンクは予測が簡単ですが (埋め込みトークンとして)、ダウンストリームのパフォーマンスが低下します。
- 長いチャンクは予測が難しくなりますが、下流のパフォーマンスが向上します。
- チャンクの数を増やすことは有益です。32 および 16 チャンクでトレーニングすると、8 または 4 チャンクでトレーニングする場合よりも下流の結果が良くなります。
- オフラインラップ率を 50% に増やすと再構築は改善されましたが、ダウンストリームのパフォーマンスは低下しました。
- GPT-2 モデルの埋め込み次元 (768 $\rightarrow$ 1024) を増やすと、ダウンストリームのパフォーマンスが向上しました。
- エンコーダー内の自己注意層の数を減らすと (6 $\rightarrow$ 4, 2)、下流のパフォーマンスが低下しました。
- GPT デコーダー レイヤー (6 $\rightarrow$ 8, 10) を追加しても、ダウンストリームのパフォーマンスは向上しませんでした。

4. 議論

大規模な EEG データセットで基礎モデルを事前トレーニングすると、下流のタスクのパフォーマンスが向上することを実証しました。さまざまな微調整戦略を検討した結果、事前トレーニング済みの EEG エンコーダーは、データセット全体に一般化できる EEG の固有の基本的な特徴を捉え、分類パフォーマンスを大幅に向上させることが分かりました。

5. 謝辞

このプロジェクトは、NIH の助成金 R01 EB026299 および国防高等研究計画局 (DARPA) の協力協定番号 N66 0012324006 に基づいて一部支援されています。情報の内容は必ずしも政府の立場や方針を反映するものではなく、公式の承認を意味するものではありません。

6. REFERENCES

- [1] Y. Du et al., “Eeg temporal–spatial transformer for person identification,” *Scientific Reports*, vol. 12, no. 1, pp. 14378, 2022.
- [2] C. J. Reed et al., “Self-supervised pretraining improves self-supervised pretraining,” in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2022, pp. 2584–2594.
- [3] L. Yu et al., “Language model beats diffusion – tokenizer is key to visual generation,” 2023.
- [4] K. Singhal et al., “Towards expert-level medical question answering with large language models,” 2023.
- [5] A. Thomas et al., “Self-supervised learning of brain dynamics from broad neuroimaging data,” *Advances in Neural Information Processing Systems*, vol. 35, pp. 21255–21269, 2022.
- [6] J. Ortega Caro et al., “Brainlm: A foundation model for brain activity recordings,” *bioRxiv*, pp. 2023–09, 2023.
- [7] M. Azabou et al., “A unified, scalable framework for neural population decoding,” 2023.
- [8] D. Kostas, S. Aroca-Ouellette, and F. Rudzicz, “Bendr: using transformers and a contrastive self-supervised learning task to learn from massive amounts of eeg data,” 2021.
- [9] J. Devlin et al., “Bert: Pre-training of deep bidirectional transformers for language understanding,” *arXiv preprint arXiv:1810.04805*, 2018.
- [10] A. Radford et al., “Language models are unsupervised multitask learners,” *OpenAI blog*, vol. 1, no. 8, pp. 9, 2019.
- [11] I. Obeid and J. Picone, “The temple university hospital eeg data corpus,” *Frontiers in neuroscience*, vol. 10, pp. 196, 2016.
- [12] C. Q. Lai et al., “Artifacts and noise removal for electroencephalogram (eeg): A literature review,” in *2018 IEEE Symposium on Computer Applications & Industrial Electronics (ISCAIE)*. IEEE, 2018, pp. 326–332.
- [13] Y. Song et al., “EEG Conformer: Convolutional Transformer for EEG Decoding and Visualization,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 31, pp. 710–719, 2023.
- [14] T. B. Brown et al., “Language models are few-shot learners,” 2020.
- [15] F. Tadel et al., “Brainstorm: a user-friendly application for meg/eeg analysis,” *Computational intelligence and neuroscience*, vol. 2011, pp. 1–13, 2011.
- [16] T. Wolf et al., “Huggingface’s transformers: State-of-the-art natural language processing,” 2020.
- [17] C. Brunner et al., “Bci competition 2008–graz data set a,” *Institute for Knowledge Discovery (Laboratory of Brain-Computer Interfaces)*, Graz University of Technology, vol. 16, pp. 1–6, 2008.
- [18] J. C. Mosher et al., “Eeg and meg: forward solutions for inverse methods,” *IEEE Transactions on biomedical engineering*, vol. 46, no. 3, pp. 245–259, 1999.
- [19] S. Baillet et al., “Electromagnetic brain mapping,” *IEEE Signal processing magazine*, vol. 18, no. 6, pp. 14–30, 2001.
- [20] C. Zhang et al., “Eeg-inception: an accurate and robust end-to-end neural network for eeg-based motor imagery classification,” *Journal of Neural Engineering*, vol. 18, no. 4, pp. 046014, 2021.
- [21] V. P. Oikonomou et al., “A comparison study on eeg signal processing techniques using motor imagery eeg data,” in *2017 IEEE 30th international symposium on computer-based medical systems (CBMS)*. IEEE, 2017, pp. 781–786.
- [22] V. J. Lawhern et al., “Eegnet: a compact convolutional neural network for eeg-based brain–computer interfaces,” *Journal of neural engineering*, vol. 15, no. 5, pp. 056013, 2018.
- [23] R. T. Schirrmeister et al., “Deep learning with convolutional neural networks for eeg decoding and visualization,” *Human brain mapping*, vol. 38, no. 11, pp. 5391–5420, 2017.
- [24] S. U. Amin et al., “Deep learning for eeg motor imagery classification based on multi-layer cnns feature fusion,” *Future Generation computer systems*, vol. 101, pp. 542–554, 2019.
- [25] D. Zhang et al., “Motor imagery classification via temporal attention cues of graph embedded eeg signals,” *IEEE journal of biomedical and health informatics*, vol. 24, no. 9, pp. 2570–2579, 2020.

6. 参考文献

- [1] Y. Du他、「人物識別のためのEeg時空間変換器」、*Scientific Reports*、第12巻第1号、pp.14378、2022年。
- [2] C. J. Reed他、「自己教師あり事前学習は自己教師あり事前学習を改善する」、*Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*、2022年、2584-2594頁。
- [3] L. Yu他「言語モデルが拡散に勝つ - トークン化が視覚生成の鍵」2023年。
- [4] K. Singhal他「大規模言語モデルによる専門家レベルの医療質問回答に向けて」2023年。
- [5] A. Thomasら、「広範な神経画像データからの脳ダイナミクスの自己教師学習」、*Advances in Neural Information Processing Systems*、第35巻、pp.21255-21269、2022年。
- [6] J. Ortega Caro 他、「Brainlm: 脳活動記録の基礎モデル」*bioRxiv*、2023-09 ページ、2023年。
- [7] M. Azabou他「ニューラル集団デコードのための統一されたスケーラブルなフレームワーク」、2023年。
- [8] D. Kostas、S. Aroca-Ouellette、F. Rudzicz、「Bendr : トランスフォーマーと対照的自己教師学習タスクを使用して大量のEEGデータから学習する」、2021年。
- [9] J. Devlin他「Bert : 言語理解のための深層双方向変換器の事前トレーニング」*arXiv preprint arXiv:1810.04805*、2018年。
- [10] A. Radford他「言語モデルは教師なしマルチタスク学習者である」*OpenAI blog*、第1巻第8号、9頁、2019年。
- [11] I. ObeidとJ. Picone、「テンプル大学病院脳波データコーパス」、*Frontiers in neuroscience*、第10巻、196頁、2016年。
- [12] C. Q. Laiら、「脳波 (EEG) のアーティファクトとノイズ除去: 文献レビュー」、2018 *IEEE Symposium on Computer Applications & Industrial Electronics (ISCAIE)*。IEEE、2018年、326~332頁。
- [13] Y. Songら、「EEGコンフォーマー: EEGデコードおよび視覚化のための畳み込み変換器」、*IEEE Transactions on Neural Systems and Rehabilitation Engineering*、第31巻、pp.710-719、2023年。
- [14] T. B. Brown他「言語モデルは少数ショット学習者である」2020年。
- [15] F. Tadelら、「Brainstorm: 脳波/脳波分析のためのユーザーフレンドリーなアプリケーション」、*Computational intelligence and neuroscience*、2011年巻、1-13頁、2011年。
- [16] T. Wolf他「Huggingfaceのトランスフォーマー: 最先端の自然言語処理」、2020年。
- [17] C. Brunner et al.、「Bciコンペティション2008-グラフデータセットA」、*Institute for Knowledge Discovery (Laboratory of Brain-Computer Interfaces), Graz University of Technology*、第16巻、pp.1-6、2008年。
- [18] J. C. Mosher他、「Eegとmeg: 逆問題法の順方向解法」、第46巻第3号、245-259頁、1999年。
- [19] S. Baillet他「電磁脳マッピング」、第18巻第6号、1-4-30頁、2001年。
- [20] C. Zhangら、「EEGインセプション: EEGベースの運動イメージ分類のための正確で堅牢なエンドツーエンドのニューラルネットワーク」、*Journal of Neural Engineering*、第18巻第4号、pp.046014、2021年。
- [21] V. P. Oikonomou他「運動イメージング脳波データを用いた脳波信号処理技術の比較研究」、*2017 IEEE 30th international symposium on computer-based medical systems (CBMS)*。IEEE、2017年、781-786頁。
- [22] V. J. Lawhern他「Eegnet: 脳波ベースの脳コンピューターインターフェースのためのコンパクトな畳み込みニューラルネットワーク」、*Journal of neural engineering*、第15巻第5号、pp.056013、2018年。
- [23] R. T. Schirrmeister他「脳波のデコードと可視化のための畳み込みニューラルネットワークによる深層学習」、*Human brain mapping*、第38巻、第11号、pp.5391-5420、2017年。
- [24] S. U. Amin他「多層CNNs特徴融合に基づく脳波運動イメージ分類のための深層学習」、*Future Generation computer systems*、第101巻、pp.542-554、2019年。
- [25] D. Zhang et al.、「グラフに埋め込まれた脳波信号の時間的注意キューによる運動イメージ分類」、*IEEE journal of biomedical and health informatics*、第24巻、第9号、pp.2570-2579、2020年。